ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP LỚN A1

SO SÁNH RESNET18 VÀ VIT-B/16 TRÊN TẬP DỮ LIỆU CIFAR-100

Học phần: Học sâu và ứng dụng trong thị giác máy tính

Mã học phần: CO5085 | Học kỳ: HK261 (2026–2027)

Học viên: Ngô Duy Bảo | Mã số học viên: 2570395

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Mã nguồn: github.com/baond12/Deep_Learning_Course_HK261

MỤC LỤC

TÓM TẮT....3
CHƯƠNG 1. MỤC TIÊU VÀ PHẠM VI NGHIÊN CỨU....4
CHƯƠNG 2. TẬP DỮ LIỆU VÀ QUY TRÌNH XỬ LÝ....6
CHƯƠNG 3. KIẾN TRÚC VÀ CÁC CẤU HÌNH THỰC NGHIỆM....9
CHƯƠNG 4. QUY TRÌNH HUẤN LUYỆN VÀ ĐÁNH GIÁ....11
CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH....13
CHƯƠNG 6. THẢO LUẬN, GIỚI HẠN VÀ KẾT LUẬN....22
TÀI LIỆU THAM KHẢO....23
PHỤ LỤC A. HỒ SƠ THỰC NGHIỆM VÀ KHẢ NĂNG KIỂM CHỨNG....24
PHỤ LỤC B. HÌNH MA TRẬN NHẦM LẪN (MINH HỌA TỔNG QUAN)....25
PHỤ LỤC C. TUYÊN BỐ HỖ TRỢ CỦA TRÍ TUỆ NHÂN TẠO....26

Để cập nhật số trang sau khi chỉnh sửa: chọn mục lục rồi nhấn F9 (hoặc nhấn Ctrl+A, F9 trong Word).

TÓM TẮT

Báo cáo khảo sát sự khác biệt giữa mạng nơ-ron tích chập và Transformer thị giác trong bài toán phân loại ảnh nhiều lớp, đồng thời đánh giá ảnh hưởng của trọng số tiền huấn luyện và phạm vi tham số được phép cập nhật. Hai kiến trúc được lựa chọn là ResNet18 và Vision Transformer ViT-B/16. Tập CIFAR-100 có 100 lớp được phân chia theo giao thức cân bằng thành 40.000 ảnh huấn luyện, 10.000 ảnh xác thực và 10.000 ảnh kiểm tra. Mỗi kiến trúc được khảo sát với bốn cấu hình: huấn luyện từ đầu, chỉ huấn luyện đầu phân loại, tinh chỉnh một phần mạng và tinh chỉnh toàn bộ.

Kết quả ghi nhận ở tám cấu hình cho thấy ViT-B/16 tinh chỉnh một phần có độ chính xác kiểm tra cao nhất, 83,25%, cùng F1 trung bình theo lớp đạt 0,8324. Trong nhóm ResNet18, tinh chỉnh toàn bộ dẫn đầu với độ chính xác 76,84%. Ngược lại, ViT-B/16 huấn luyện từ đầu chỉ đạt 35,30% và có mất mát không hữu hạn từ lượt huấn luyện thứ 11. Cấu hình ViT tinh chỉnh toàn bộ cũng phát sinh bất thường tương tự từ lượt thứ 37. Các đánh giá cuối được thực hiện trên trạng thái có độ chính xác xác thực tốt nhất theo quy trình trong mã nguồn, không nhất thiết là trạng thái của lượt huấn luyện cuối.

Kết luận chỉ áp dụng cho các cấu hình và lượt chạy được ghi nhận. Sáu trong tám bộ chỉ số cuối được khôi phục từ log, chưa có xác nhận độc lập về toàn bộ tham số chạy; thời gian thực nghiệm còn chịu ảnh hưởng của cách chạy song song. Báo cáo vì vậy ưu tiên so sánh độ chính xác, mô tả trung thực sai lệch giữa huấn luyện và xác thực, và chỉ xem chi phí tính toán như số liệu quan sát chưa được chuẩn hóa phần cứng.

Từ khóa: phân loại ảnh; CIFAR-100; ResNet18; ViT-B/16; tiền huấn luyện; tinh chỉnh mô hình; F1 trung bình theo lớp.

CHƯƠNG 1. MỤC TIÊU VÀ PHẠM VI NGHIÊN CỨU

1.1. Bối cảnh và vấn đề nghiên cứu

Trong phân loại ảnh, mạng nơ-ron tích chập (Convolutional Neural Network, CNN) khai thác tính cục bộ và cấu trúc không gian qua các bộ lọc tích chập. Transformer thị giác (Vision Transformer, ViT) xử lý ảnh dưới dạng chuỗi các vùng nhỏ và học mối quan hệ giữa chúng bằng cơ chế tự chú ý. Hai cách thiết kế này tạo ra những điều kiện học đặc trưng khác nhau; sự khác biệt không chỉ đến từ tên kiến trúc mà còn từ kích thước dữ liệu, cách khởi tạo trọng số và chiến lược huấn luyện [3], [4].

Bài tập lớn A1 của học phần CO5085 yêu cầu so sánh ít nhất một CNN và một Transformer trên tập ảnh công khai có độ khó cao hơn các bài thực hành cơ bản. Báo cáo này sử dụng kết quả đã ghi nhận cho ResNet18 và ViT-B/16 trên CIFAR-100, không mở rộng phạm vi sang các bài tập E1–E3 hoặc A2. Đơn vị so sánh là một cấu hình kiến trúc – chế độ huấn luyện, thay vì một tuyên bố khái quát về mọi mạng CNN hay mọi Transformer [1].

1.2. Mục tiêu và câu hỏi phân tích

Mục tiêu thứ nhất là mô tả một giao thức phân chia dữ liệu, tiền xử lý và đánh giá có thể đọc được từ mã nguồn. Mục tiêu thứ hai là đối chiếu chất lượng dự đoán của tám cấu hình theo độ chính xác, F1 trung bình theo lớp và các đường cong học. Mục tiêu thứ ba là làm rõ sự đánh đổi giữa số tham số được cập nhật, thời gian ghi nhận và chất lượng trên tập kiểm tra, nhưng không đồng nhất thời gian quan sát với phép đo tốc độ chuẩn hóa phần cứng.

- Việc sử dụng trọng số tiền huấn luyện thay đổi kết quả như thế nào so với khởi tạo ngẫu nhiên trong từng họ mô hình?
- Với cùng một kiến trúc, đóng băng backbone, mở một phần hoặc tinh chỉnh toàn bộ dẫn đến kết quả và hiện tượng học nào?
- Những giới hạn nào của dữ liệu, log thực nghiệm và tính ổn định khiến một phép so sánh chưa đủ để kết luận về ưu thế tổng quát?

1.3. Phạm vi và mốc bài tập

A1.1 tập trung vào lựa chọn dữ liệu và khóa giao thức, có hạn 26/10/2026; A1.2 yêu cầu kết quả so sánh cuối, phân tích và mã tái lập với hạn 09/11/2026. Đây là hai mốc

trong đề bài, không phải hai lần nộp được báo cáo này tự xác nhận đã hoàn thành. Bộ hồ sơ đang dùng phục vụ bản nháp Word để người học đọc, đối chiếu và chỉnh lý trước bước xuất PDF, cập nhật GitHub Pages hoặc nộp bài [1].

Phạm vi đánh giá gồm 100 lớp fine của CIFAR-100, hai kiến trúc và bốn chế độ huấn luyện trên mỗi kiến trúc. Các chỉ số test được giữ theo nguồn dữ liệu đã cung cấp; không có thí nghiệm nhiều seed, đo bộ nhớ đỉnh, thời gian suy luận, hoặc kiểm thử sức bền trước biến đổi dữ liệu. Những nội dung đó chỉ được nêu dưới dạng giới hạn hay hướng cải thiện, không bị diễn giải thành kết quả đã thực hiện.

CHƯƠNG 2. TẬP DỮ LIỆU VÀ QUY TRÌNH XỬ LÝ

2.1. Lựa chọn và nguồn CIFAR-100

CIFAR-100 do nhóm Alex Krizhevsky công bố có 60.000 ảnh màu RGB, kích thước gốc 32 × 32 điểm ảnh, thuộc 100 lớp chi tiết (fine classes). Mỗi lớp gồm 500 ảnh trong tập huấn luyện gốc và 100 ảnh trong tập kiểm tra gốc; tổng cộng tương ứng 50.000 và 10.000 ảnh. Bộ dữ liệu còn có cách nhóm thành 20 lớp lớn, nhưng các thực nghiệm ở đây sử dụng 100 nhãn chi tiết, không chuyển bài toán thành phân loại 20 lớp [2].

CIFAR-100 được chọn vì có nhiều lớp với các đối tượng và bối cảnh khác nhau, làm cho bài toán khó hơn MNIST, Fashion-MNIST và CIFAR-10 đã xuất hiện trong nội dung học phần. Quy mô 60.000 ảnh đủ để thiết lập phép so sánh trong phạm vi nguồn lực học tập, dù kích thước ảnh gốc nhỏ khiến việc phóng lên đầu vào 224 × 224 không bổ sung thông tin chi tiết bị thiếu. Bộ dữ liệu và đường dẫn tải công khai được nêu tại trang CIFAR chính thức [2].

Về điều kiện sử dụng, nguồn công bố đã kiểm tra có đường dẫn tải dữ liệu và yêu cầu trích dẫn báo cáo kỹ thuật của Krizhevsky (2009). Hồ sơ hiện có chưa xác lập một tên giấy phép chuẩn hóa riêng cho CIFAR-100. Vì vậy, báo cáo không gán giấy phép MIT, Creative Commons hay quyền sử dụng thương mại khi thiếu văn bản xác nhận; thông tin giấy phép cụ thể cần được đối chiếu bổ sung trước khi công bố bản nộp cuối.

2.2. Phân chia dữ liệu theo lớp

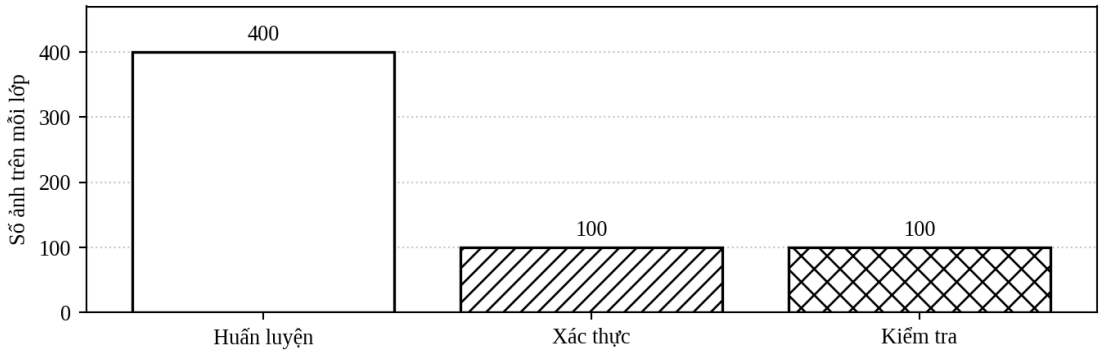
Hàm build_cifar100_balanced_loaders trong A1/data.py chọn toàn bộ 100 lớp và tách 500 ảnh huấn luyện gốc của mỗi lớp thành 400 ảnh để học tham số và 100 ảnh để xác thực. Tập kiểm tra gồm 100 ảnh/lớp từ tập test gốc. Như vậy, bộ dữ liệu học thật sự chứa 40.000 ảnh, không phải 50.000 ảnh; 10.000 ảnh còn lại của tập train gốc được dành riêng cho xác thực. Việc chia được thực hiện trước khi áp dụng biến đổi tăng cường dữ liệu.

Trong mỗi lớp, các chỉ mục được xáo trộn bởi random.Random(seed + class_id), với seed thiết kế là 42; sau khi ghép, danh sách train và validation được xáo trộn lần nữa bằng các bộ sinh ngẫu nhiên riêng. Cách thực hiện này bảo đảm số lượng cân bằng theo lớp ở cả ba tập. Bản ghi runtime gốc xác nhận seed và split cho hai lượt ResNet18

partial và ViT scratch; với sáu lượt khôi phục từ console log, việc dùng chính xác cùng tham số lúc chạy cần được kiểm chứng riêng.

Bảng 2.1. Quy mô tập dữ liệu theo giao thức được cài đặt trong mã nguồn

Tập dữ liệu	Số lớp	Ảnh/lớp	Tổng ảnh	Vai trò
Huấn luyện	100	400	40.000	Cập nhật trọng số
Xác thực	100	100	10.000	Chọn trạng thái tốt nhất
Kiểm tra	100	100	10.000	Đánh giá cuối



Hình 2.1. Phân bố số ảnh mỗi lớp theo giao thức chia tập; nguồn: A1/data.py. Đây là số lượng từ quy trình thiết kế, không phải số đo histogram pixel.

2.3. Tiền xử lý và tăng cường dữ liệu

Cả ba tập đều đưa ảnh về kích thước 224 × 224, chuyển thành tensor ba kênh và chuẩn hóa theo trung bình (0,485; 0,456; 0,406) và độ lệch chuẩn (0,229; 0,224; 0,225) tương ứng ba kênh RGB. Riêng tập huấn luyện có RandomHorizontalFlip với xác suất 0,5. Tập xác thực và kiểm tra không áp dụng phép lật ngẫu nhiên nhằm duy trì điều kiện đánh giá cố định. Không có RandomCrop, ColorJitter, MixUp hoặc CutMix trong pipeline được cung cấp.

Việc dùng các thống kê chuẩn hóa thường gắn với ImageNet tạo một giao thức chung có thể đưa vào các bản tiền huấn luyện của torchvision. Tuy nhiên, chưa có bản kiểm chứng riêng khẳng định phép nội suy và chính sách crop này trùng hoàn toàn với transforms đi kèm từng phiên bản checkpoint. Do đó, đây là mô tả đúng mã hiện có, không phải khẳng định tối ưu hóa tiền xử lý cho từng trọng số. Ảnh trong các hình phân tích được chuyển thành mức xám để in đen trắng; điều đó không thay đổi dữ liệu RGB dùng trong huấn luyện.

2.4. Nhận xét về dữ liệu và giới hạn khảo sát

Từ thống kê công bố và mã nguồn, có thể xác nhận số lớp, số mẫu dự kiến và việc giữ cân bằng giữa các nhãn. Tuy nhiên, bộ tài liệu đầu vào không kèm toàn bộ ảnh gốc nên báo cáo không nhận là đã trực tiếp kiểm tra ảnh trùng, thống kê màu, độ sáng, phân bố texture hoặc chất lượng từng lớp. Phân bố đồng đều theo số lượng không có nghĩa độ khó nhận dạng của các lớp là như nhau.

Những mẫu lỗi trong các chương sau được lấy tối đa 25 mẫu sai đầu tiên khi duyệt tập kiểm tra bằng test loader; chúng được dùng để minh họa định tính. Không thể từ vài hình này suy ra thứ hạng lớp khó nhất, tần suất từng kiểu nhầm lẫn hoặc tỉ lệ sai trong toàn bộ tập dữ liệu.

CHƯƠNG 3. KIẾN TRÚC VÀ CÁC CẤU HÌNH THỰC NGHIỆM

3.1. ResNet18: CNN sử dụng kết nối phần dư

ResNet18 là một mạng nơ-ron tích chập tổ chức thành các giai đoạn trích đặc trưng. Thành phần quan trọng là khối phần dư, cho phép cộng tín hiệu đường tắt với kết quả của chuỗi biến đổi, thường được biểu diễn ở dạng y = F(x) + x khi kích thước tương thích. Ý tưởng này tạo thêm đường truyền thông tin và gradient, hỗ trợ việc tối ưu mạng sâu [3].

Trong A1/models.py, kiến trúc được tạo bởi torchvision.models.resnet18; đầu phân loại ban đầu được thay bằng lớp tuyến tính nn.Linear(512, 100). Tổng tham số của mô hình sau thay đầu là 11.227.812. Ở chế độ chỉ học đầu phân loại, toàn bộ backbone bị đặt requires_grad=False còn lớp fc được cập nhật; ở chế độ tinh chỉnh một phần, mô hình mở thêm layer4. Hai chế độ huấn luyện từ đầu và tinh chỉnh toàn bộ cho phép cập nhật tất cả tham số.

3.2. ViT-B/16: Transformer thị giác

ViT-B/16 chia ảnh thành những ô 16 × 16 điểm ảnh. Với đầu vào 224 × 224, số ô ảnh là $(224/16)^2 = 196$. Mỗi ô được biến đổi thành vector đặc trưng, ghép cùng token phân loại và thông tin vị trí để đưa qua các khối Transformer. Các khối tự chú ý tạo điều kiện kết hợp thông tin từ những vùng khác nhau của ảnh [4].

ViT-B/16 trong mã được khởi tạo từ torchvision.models.vit_b_16 và thay heads.head bằng nn.Linear(768, 100). Tổng tham số của mô hình sau thay đầu là 85.875.556. Ở chế độ chỉ học đầu, bộ phân loại có 76.900 tham số được cập nhật. Chế độ tinh chỉnh một phần chỉ mở hai khối encoder cuối và heads, không mở thêm encoder.ln; chế độ toàn bộ mở tất cả các tham số. Các giá trị đếm tham số của một số lượt chạy là phép suy ra từ định nghĩa mô hình hiện tại, không phải kết quả đếm được lưu trong log thực nghiệm tương ứng.

3.3. Bốn chế độ huấn luyện trên mỗi họ

Bảng 3.1. Phạm vi cập nhật tham số ở tám cấu hình

Mã cấu hình	Khởi tạo	Phạm vi được học

Mã cấu hình	Khởi tạo	Phạm vi được học
ResNet từ đầu	Ngẫu nhiên	Toàn bộ ResNet18
ResNet chỉ đầu	Tiền huấn luyện	Chỉ fc
ResNet một phần	Tiền huấn luyện	layer4 + fc
ResNet toàn bộ	Tiền huấn luyện	Toàn bộ ResNet18
ViT từ đầu	Ngẫu nhiên	Toàn bộ ViT-B/16
ViT chỉ đầu	Tiền huấn luyện	Chỉ heads
ViT một phần	Tiền huấn luyện	2 khối encoder cuối + heads
ViT toàn bộ	Tiền huấn luyện	Toàn bộ ViT-B/16

Trong mã hiện tại, tên chế độ bắt đầu bằng pretrained sẽ chọn ResNet18_Weights.DEFAULT hoặc ViT_B_16_Weights.DEFAULT khi download_weights=True. Nếu chạy với cờ --no-download-weights, cả cấu hình có tên pretrained cũng có thể nhận weights=None. Vì chưa có nguyên dòng lệnh của sáu lượt được khôi phục từ log, báo cáo giữ đúng tên thí nghiệm được cung cấp nhưng không khẳng định đã xác nhận checkpoint hay phiên bản weight enum thực tế ở từng phiên chạy.

3.4. Số tham số và ý nghĩa của việc đóng băng

Số tham số của mô hình biểu thị kích thước tập trọng số; số tham số được huấn luyện cho biết bao nhiêu giá trị được cho phép cập nhật bằng gradient. Hai đại lượng này không tương đương. Ví dụ, ViT chỉ học đầu vẫn giữ tổng cộng 85.875.556 tham số trong mô hình nhưng chỉ cập nhật 76.900 tham số của heads. Chế độ một phần dùng 14.252.644 tham số được học, gồm hai khối encoder cuối và đầu phân loại.

Cơ chế đóng băng trong A1/models.py chỉ thay đổi requires_grad. Trong vòng lặp huấn luyện, model.train() vẫn được gọi cho toàn mô hình. Đối với ResNet18, các lớp BatchNorm có thể tiếp tục cập nhật thống kê chạy ở chế độ train, ngay cả khi trọng số bị đóng băng. Vì thế, cụm từ “chỉ học đầu” ở đây chỉ mô tả tham số được cập nhật bằng gradient, không chứng minh rằng mọi trạng thái của backbone bất biến. Nhận xét này là suy luận từ mã và tài liệu BatchNorm, chưa có thí nghiệm tách riêng ảnh hưởng đó [5].

CHƯƠNG 4. QUY TRÌNH HUẤN LUYỆN VÀ ĐÁNH GIÁ

4.1. Cấu hình và phạm vi thông tin xác nhận

Theo A1/train.py và common/engine.py, mô hình được tối ưu bằng Adam cùng hàm mất mát CrossEntropyLoss. Mạng trả về logits, tức các điểm số chưa chuẩn hóa; CrossEntropyLoss tiếp nhận logits trực tiếp và không cần thực hiện softmax bằng tay trước khi tính mất mát. Với mỗi lô ảnh, chương trình lần lượt xóa gradient, chạy mô hình, tính mất mát, lan truyền ngược và cập nhật tham số.

Cả tám tệp lịch sử chứa 50 lượt huấn luyện (epoch), tổng 400 hàng dữ liệu. Metadata JSON gốc của ResNet18 tinh chỉnh một phần và ViT huấn luyện từ đầu ghi kích thước lô 16, learning rate 10^{-4}, weight decay 10^{-4}, CUDA và seed 42. Sáu lượt còn lại có đủ lịch sử, epoch tốt nhất và kết quả cuối nhưng không có bản ghi độc lập xác nhận đầy đủ các thông số runtime. Những giá trị 5 epoch và batch size 32 trong dòng lệnh ví dụ của README/COLAB không phải cấu hình thực nghiệm của 400 epoch đã ghi nhận.

Bảng 4.1. Phạm vi xác nhận của các thiết lập huấn luyện

Nội dung	Bằng chứng hiện có	Giới hạn
50 epoch	Đủ 8 lịch sử CSV	Có xác nhận từng lượt
Split 40k/10k/10k, seed 42	Mã và metadata của 2 JSON gốc	Sáu log cần xác nhận runtime
Adam, CE, LR 10^{-4}, WD 10^{-4}	Mã hiện tại; metadata 2 lượt	Chưa có dòng lệnh 6 lượt
CUDA, batch 16	Metadata 2 JSON gốc	Không suy rộng cho toàn bộ 8 lượt
Bộ nhớ và GPU cụ thể	Không có trong hồ sơ	Chưa đo/không tự bổ sung

4.2. Lựa chọn trạng thái mô hình

Sau mỗi epoch, chương trình tính độ chính xác trên tập xác thực và chỉ lưu bản sao state_dict khi val_accuracy tăng nghiêm ngặt so với mức tốt nhất trước đó. Nếu hai epoch bằng nhau, epoch đạt trước được giữ lại. Khi vòng lặp kết thúc, trạng thái tốt nhất này được nạp trở lại mô hình rồi mới thực hiện đánh giá trên tập kiểm tra. Việc lựa chọn do tập xác thực quyết định, không dùng tập kiểm tra để tối ưu hoặc chọn epoch.

Trong mã hiện tại không có lịch điều chỉnh tốc độ học (learning-rate scheduler), dừng sớm, clipping gradient hoặc cơ chế huấn luyện hỗn hợp độ chính xác (mixed precision). Đánh giá test được thực hiện sau khi chọn trạng thái tốt nhất. Hai lượt ViT gặp NaN trong quá trình học vẫn có thể cho chỉ số test hữu hạn vì trạng thái được khôi

phục để đánh giá đã được ghi nhận từ trước thời điểm lỗi. Không thể từ điều này kết luận toàn bộ tiến trình 50 epoch của chúng là ổn định.

4.3. Chỉ số đánh giá và nguyên tắc so sánh

Độ chính xác (accuracy) là tỷ lệ số dự đoán đúng trên tổng số mẫu. Với K = 100 lớp, F1 trung bình theo lớp (macro F1) là trung bình cộng điểm F1 của từng lớp: Macro F1 = $(1/K) \times \Sigma F1_k$. Điểm $F1_k$ kết hợp precision và recall cho lớp k thông qua trung bình điều hòa. Các chỉ số này bổ sung cho nhau: accuracy đo tỷ lệ đúng tổng thể, còn macro F1 phản ánh kết quả trung bình qua các lớp và tránh việc một lớp có nhiều mẫu quyết định toàn bộ giá trị [6].

Mỗi lượt có độ chính xác xác thực tốt nhất, mất mát test, độ chính xác test, macro F1, số tham số tổng/được học và thời gian huấn luyện. Theo mã, thời gian được tính từ lúc bắt đầu đến khi kết thúc fit_classifier, gồm cả huấn luyện, xác thực và thao tác lưu/nạp trạng thái trong bộ nhớ, không gồm các bước đánh giá test và vẽ đồ thị. Người học cho biết các lượt được chạy song song, còn hồ sơ không ghi phần cứng và cách phân bổ tài nguyên cụ thể; bởi vậy thời gian chỉ dùng để mô tả thời lượng quan sát được, không dùng làm tỷ lệ tăng tốc công bằng hay độ trễ suy luận.

CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

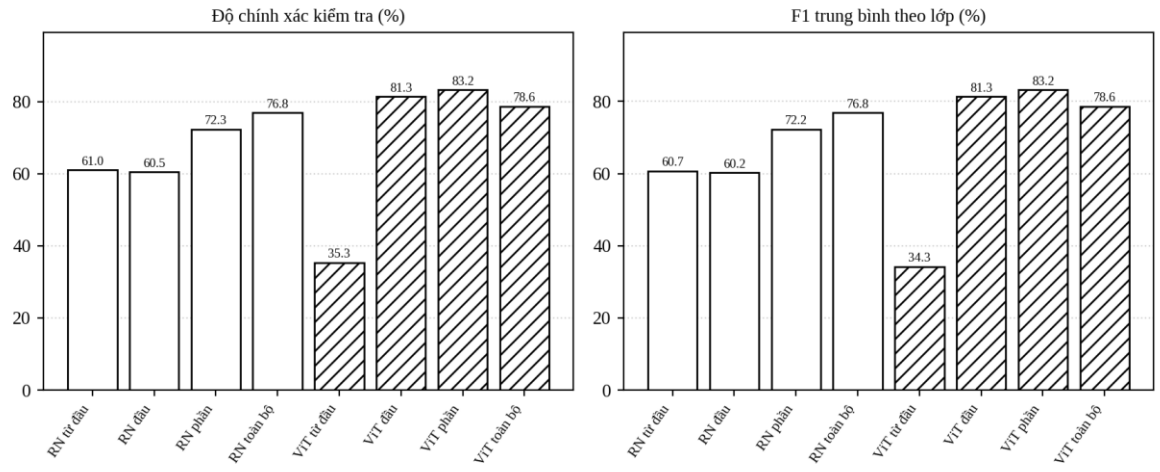
5.1. Kết quả chất lượng trên tám cấu hình

Bảng 5.1 thống nhất thang độ chính xác ở đơn vị phần trăm và biểu diễn F1 ở thang 0–1. Test loss và F1 được giữ số chữ số thập phân theo nguồn: hai bộ JSON gốc giữ độ chính xác gốc, sáu lượt khôi phục từ console log chỉ có bốn chữ số thập phân. Giá trị validation là độ chính xác cao nhất trong quá trình huấn luyện; giá trị test được đo riêng trên trạng thái đã chọn, không hoán đổi hai chỉ số.

Bảng 5.1. Kết quả chất lượng của tám cấu hình trên CIFAR-100

Cấu hình	Epoch tốt nhất	Val acc (%)	Test loss	Test acc (%)	Macro F1
ResNet từ đầu	19	61,64	1,5821	60,97	0,6070
ResNet chỉ đầu	40	61,08	1,4319	60,47	0,6022
ResNet một phần	7	72,83	1,050193	72,27	0,722477
ResNet toàn bộ	11	77,29	0,9163	76,84	0,7685
ViT từ đầu	10	35,37	2,54557	35,30	0,342563
ViT chỉ đầu	19	82,18	0,6376	81,32	0,8130
ViT một phần	27	83,66	0,9088	83,25	0,8324
ViT toàn bộ	3	78,73	0,7332	78,64	0,7859

Nguồn: bảng kết quả tổng hợp 07 và JSON 06. ResNet một phần và ViT từ đầu lấy từ JSON gốc; sáu hàng còn lại khôi phục từ log. Dấu phẩy được dùng làm dấu thập phân trong toàn bộ bảng.



Hình 5.1. Độ chính xác kiểm tra và F1 trung bình theo lớp của tám cấu hình; nguồn: 06–07. Cột gạch chéo biểu thị họ ViT-B/16.

5.2. Phân tích kết quả trong họ ResNet18

Với ResNet18, mô hình tinh chỉnh toàn bộ có độ chính xác test cao nhất 76,84%, tiếp theo là tinh chỉnh một phần 72,27%, huấn luyện từ đầu 60,97% và chỉ huấn luyện đầu

60,47%. Chênh lệch giữa tinh chỉnh toàn bộ và huấn luyện từ đầu là 15,87 điểm phần trăm. Điều này cho thấy trọng số tiền huấn luyện kết hợp điều chỉnh các lớp trích đặc trưng có thể mang lại lợi ích rõ rệt trong phạm vi thực nghiệm được ghi nhận.

Kết quả chỉ học đầu thấp hơn mô hình từ đầu 0,50 điểm phần trăm, do đó không thể coi tiền huấn luyện là lợi thế tự động khi backbone được giữ cố định ở mức tham số. Một cách giải thích có thể là biểu diễn cố định chưa tương thích hoàn toàn với 100 nhãn fine; song báo cáo không có thí nghiệm đối chứng để quy nguyên nhân cho riêng biểu diễn, thống kê BatchNorm hay chế độ tiền xử lý. F1 trung bình theo lớp của ResNet toàn bộ đạt 0,7685 và của ResNet một phần là 0,722477, phù hợp với thứ tự chất lượng theo accuracy.

5.3. Phân tích kết quả trong họ ViT-B/16

Với ViT-B/16, tinh chỉnh một phần đạt 83,25% accuracy test và macro F1 = 0,8324, đứng đầu tất cả tám cấu hình. Chỉ huấn luyện đầu đạt 81,32%, thấp hơn cấu hình một phần 1,93 điểm phần trăm. Tinh chỉnh toàn bộ đạt 78,64%, thấp hơn chỉ học đầu 2,68 điểm phần trăm; còn huấn luyện từ đầu đạt 35,30%. Thứ tự này cho thấy mở thêm tham số không tất yếu cải thiện kết quả trong giao thức đã thử.

Chênh lệch rất lớn giữa ViT tiền huấn luyện và ViT từ đầu nhất quán với lập luận rằng Transformer thị giác thường hưởng lợi từ các biểu diễn đã được học trên dữ liệu quy mô lớn [4]. Tuy nhiên, ViT từ đầu phát sinh loss NaN từ epoch 11; vì vậy phần chênh lệch cũng phản ánh tính bất ổn của lượt thử cụ thể, không phải phép đo cô lập năng lực học từ đầu của ViT trong mọi điều kiện.

Một quan sát cần được phân biệt là ViT tinh chỉnh một phần có test loss = 0,9088, lớn hơn ViT chỉ học đầu (0,6376), dù accuracy và macro F1 đều cao hơn. Cross-entropy phụ thuộc không chỉ số dự đoán đúng mà còn mức xác suất mô hình gán cho nhãn thật; vì vậy thứ tự loss có thể khác thứ tự accuracy. Hồ sơ không chứa bảng xác suất kiểm tra đủ để kết luận về hiệu chuẩn xác suất hay đo Expected Calibration Error.

5.4. Đối chiếu trực tiếp CNN và Transformer theo chế độ

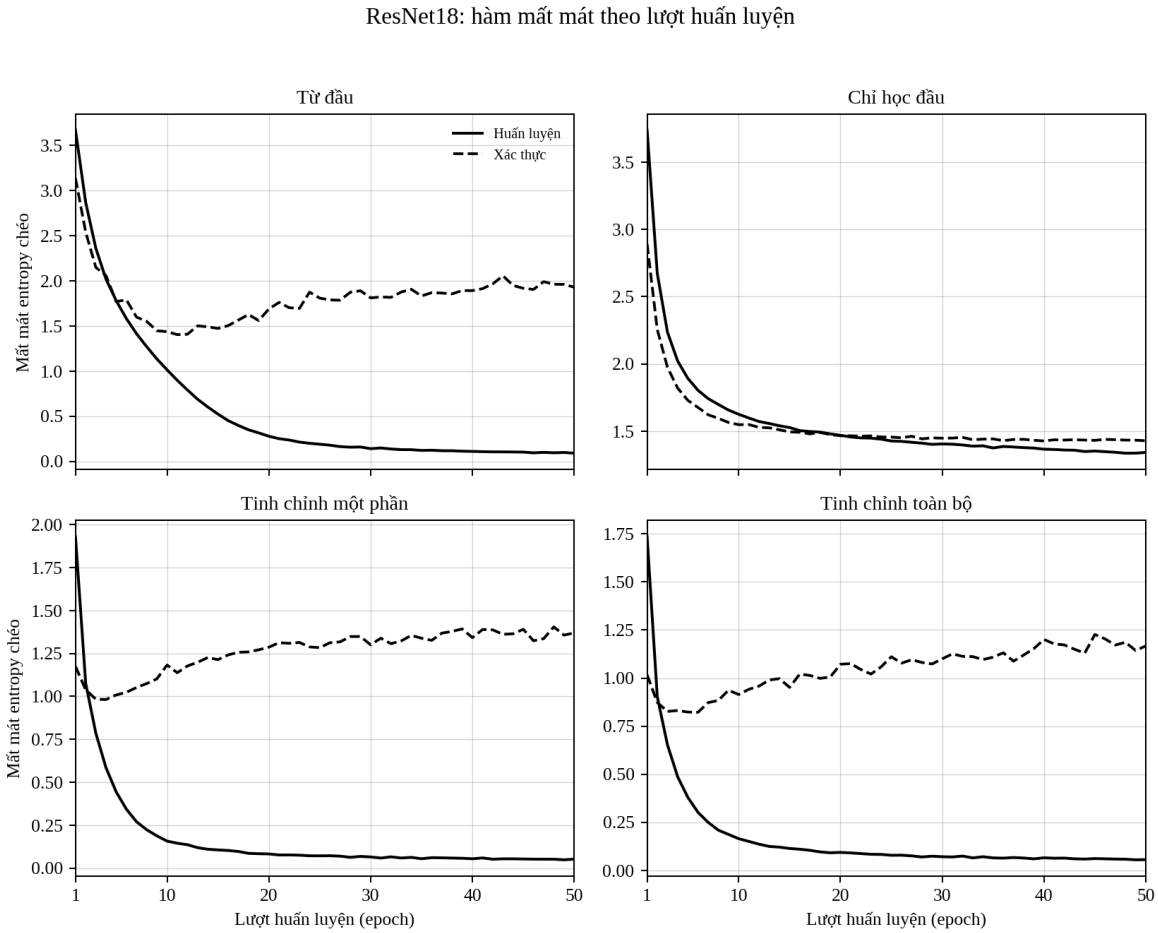
Bảng 5.2. Chênh lệch độ chính xác test theo từng chế độ (điểm phần trăm)

Chế độ	ResNet18 (%)	ViT-B/16 (%)	ViT – ResNet (đpp)

Chế độ	ResNet18 (%)	ViT-B/16 (%)	ViT – ResNet (đpp)
Huấn luyện từ đầu	60,97	35,30	−25,67
Chỉ học đầu	60,47	81,32	+20,85
Tinh chỉnh một phần	72,27	83,25	+10,98
Tinh chỉnh toàn bộ	76,84	78,64	+1,80

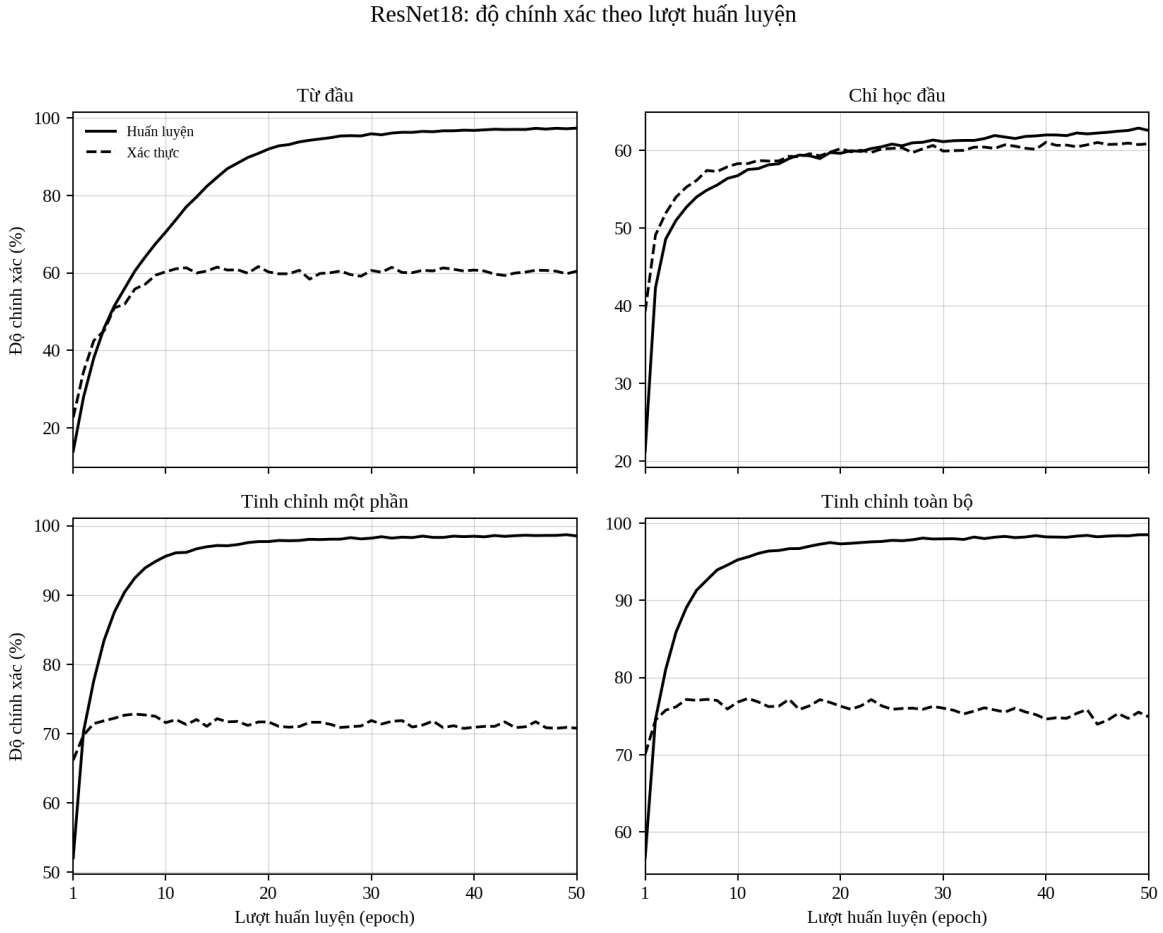
Ở ba chế độ có tên pretrained, ViT-B/16 có độ chính xác test cao hơn ResNet18 cùng tên chế độ, từ 1,80 đến 20,85 điểm phần trăm. Ngược lại, khi học từ đầu, ResNet18 cao hơn ViT-B/16 25,67 điểm phần trăm. Đây là phép đối chiếu mô tả giữa các lượt chạy đã thu thập, chưa được kiểm soát đầy đủ về phiên bản mã, phần cứng và tham số runtime cho sáu lượt bổ sung. Không nên diễn giải nó như một khẳng định Transformer luôn trội hơn CNN khi tiền huấn luyện, hoặc ResNet luôn trội hơn ViT khi học từ đầu.

5.5. Đường cong học của ResNet18



Hình 5.2. Hàm mất mát của bốn cấu hình ResNet18 theo epoch; nguồn: lịch sử 08, vẽ lại từ dữ liệu huấn luyện và xác thực.

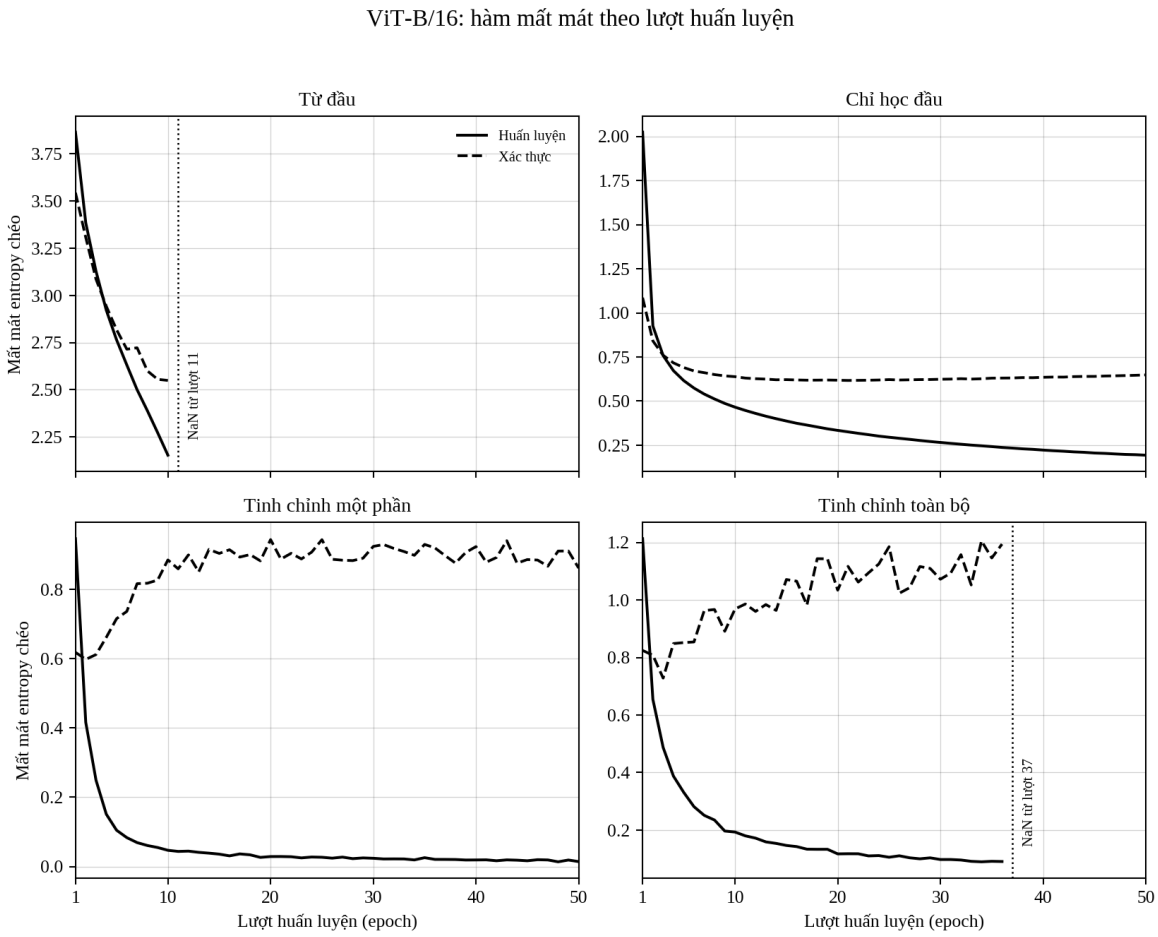
Hình 5.2 cho thấy hàm mất mát huấn luyện của các cấu hình ResNet18 giảm liên tục trong khi mất mát xác thực ở scratch, partial và full có xu hướng tăng ở giai đoạn muộn. Điều này tương ứng với khoảng cách ngày càng lớn giữa hiệu quả trên tập học và tập xác thực, là dấu hiệu cần xem xét về hiện tượng học quá khớp. Ở head-only, hai đường mất mát tiến gần nhau hơn và biến thiên tương đối nhỏ khi huấn luyện tiếp.



Hình 5.3. Độ chính xác huấn luyện và xác thực của bốn cấu hình ResNet18; nguồn: lịch sử 08.

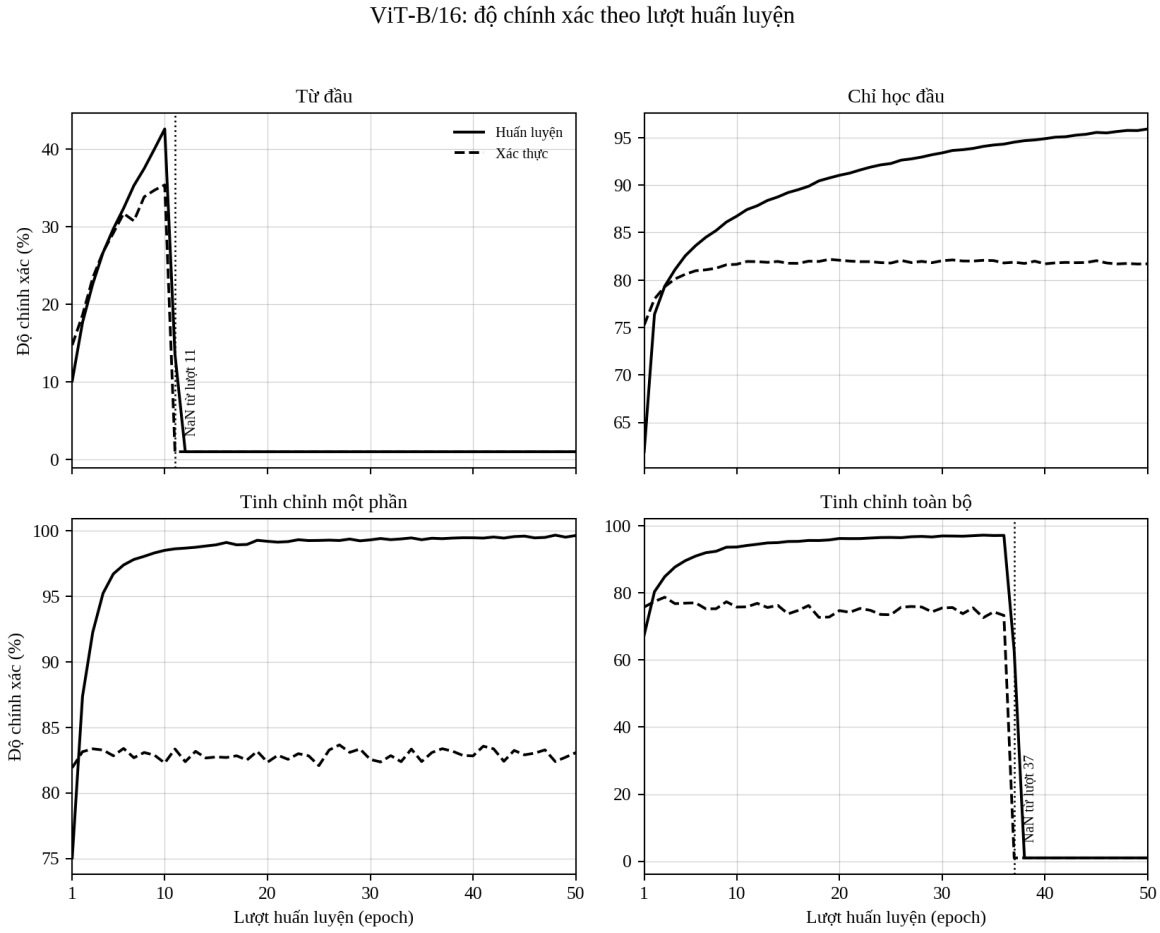
Đường accuracy giải thích vì sao cần chọn epoch bằng tập xác thực thay vì lấy mô hình sau epoch 50. Chẳng hạn, ResNet18 partial có độ chính xác xác thực tốt nhất ở epoch 7 (72,83%) nhưng đến epoch 50 còn 70,80%, trong khi accuracy huấn luyện đạt khoảng 98,53%. ResNet18 full đạt xác thực tốt nhất ở epoch 11 (77,29%) và kết thúc ở 74,91%. Sự khác biệt giữa tập học và tập xác thực phản ánh giới hạn khái quát hóa của mô hình khi tiếp tục tối ưu trên cùng tập học.

5.6. Đường cong học của ViT-B/16



Hình 5.4. Hàm mất mát của bốn cấu hình ViT-B/16. Đường dọc chấm đánh dấu epoch bắt đầu loss NaN; không thay NaN bằng 0 hoặc nội suy.

ViT chỉ học đầu có mất mát huấn luyện giảm ổn định và mất mát xác thực quanh mức 0,6–0,65 sau giai đoạn đầu. ViT tinh chỉnh một phần giảm mạnh mất mát huấn luyện tới gần 0 nhưng mất mát xác thực dao động quanh mức cao hơn; tuy accuracy xác thực vẫn có thể tốt hơn. Ở cấu hình ViT từ đầu, hai đường mất mát trở thành không hữu hạn từ epoch 11; ở cấu hình tinh chỉnh toàn bộ, bất thường bắt đầu từ epoch 37. Các đoạn không có dữ liệu hữu hạn được để trống thay vì vẽ đường biểu diễn giả.



Hình 5.5. Độ chính xác huấn luyện và xác thực của bốn cấu hình ViT-B/16; epoch lỗi được đánh dấu để tránh hiểu nhầm hội tụ.

ViT partial đạt độ chính xác xác thực tốt nhất 83,66% ở epoch 27 dù độ chính xác huấn luyện tiến sát 100%; ViT head đạt xác thực tốt nhất 82,18% ở epoch 19. ViT toàn bộ đạt xác thực tốt nhất ngay epoch 3 với 78,73%, không phải ở giai đoạn sau trước khi NaN xuất hiện. Đường accuracy rơi về khoảng 1% sau lỗi của một số lượt ViT là một triệu chứng đi kèm trong history, không thay thế việc xác định nguyên nhân số học của NaN.

5.7. Bất thường NaN và giới hạn diễn giải

Bảng 5.3. Hai cấu hình ViT có mất mát không hữu hạn

Cấu hình	NaN từ epoch	Epoch tốt nhất	Val acc tốt nhất	Test acc
ViT từ đầu	11	10	35,37%	35,30%
ViT toàn bộ	37	3	78,73%	78,64%

Sự xuất hiện NaN là bằng chứng trực tiếp về mất tính hữu hạn của giá trị loss trong history chứ không phải lý do để tự điền 0 vào biểu đồ. Theo common/engine.py, bản

sao state_dict của epoch có val_accuracy tốt nhất được nạp lại sau vòng lặp, do đó mô hình dùng để đánh giá test có thể không chứa trạng thái lỗi ở các epoch cuối. Với ViT từ đầu, epoch tốt nhất là 10, nằm trước thời điểm NaN ở epoch 11; tương tự, ViT toàn bộ chọn epoch 3 trước khi NaN từ epoch 37.

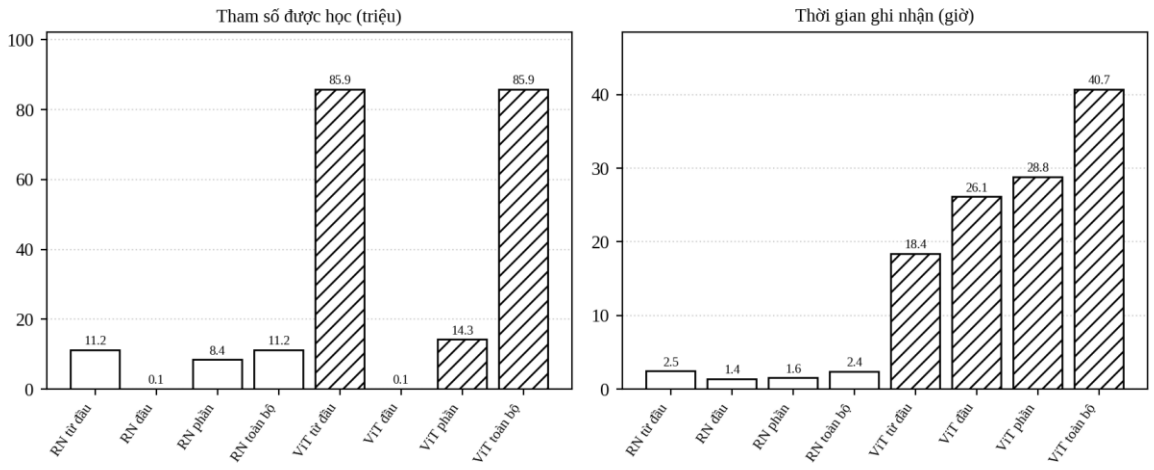
Không có bản ghi gradient, trị riêng của kích hoạt, thống kê mixed precision, dữ liệu phần cứng hoặc thí nghiệm tái lập để quy NaN cho learning rate, overflow, cách chuẩn hóa hay một bộ phận cụ thể của mạng. Việc kiểm tra tensor không hữu hạn, giảm learning rate, thử clipping gradient và theo dõi chuẩn gradient là những hướng thử tiếp theo, chưa được thực hiện trong hồ sơ. Kết quả test hiện hữu vẫn được báo cáo nhưng phải kèm nhãn giới hạn ổn định thay vì mô tả sai là mô hình hoàn tất 50 epoch ổn định.

5.8. Chi phí huấn luyện và số tham số

Bảng 5.4. Quy mô tham số và thời gian quan sát của tám cấu hình

Cấu hình	Tổng tham số	Tham số được học	Thời gian ghi nhận
ResNet từ đầu	11.227.812	11.227.812	2h 27m 17s
ResNet chỉ đầu	11.227.812	51.300	1h 24m 4s
ResNet một phần	11.227.812	8.445.028	1h 33m 4s
ResNet toàn bộ	11.227.812	11.227.812	2h 25m 35s
ViT từ đầu	85.875.556	85.875.556	18h 23m 37s
ViT chỉ đầu	85.875.556	76.900	26h 8m 14s
ViT một phần	85.875.556	14.252.644	28h 48m 53s
ViT toàn bộ	85.875.556	85.875.556	40h 44m 46s

Nguồn tham số: hai bộ JSON gốc của ResNet một phần và ViT từ đầu; sáu giá trị còn lại suy ra theo A1/models.py hiện tại. Thời gian sáu log chỉ có độ chính xác đến giây, và người học cho biết có chạy song song.



Hình 5.6. Số tham số được học và thời gian ghi nhận của tám lượt; biểu đồ không đại diện cho phép benchmark phần cứng được kiểm soát.

Chế độ chỉ huấn luyện đầu làm giảm số tham số cần cập nhật xuống 51.300 (ResNet18) hoặc 76.900 (ViT-B/16), nhưng không làm biến mất các tham số của backbone khi suy luận. ViT-B/16 có tổng 85.875.556 tham số, lớn hơn đáng kể ResNet18 với 11.227.812; từ số lượng tham số có thể thảo luận xu hướng nhu cầu lưu trữ trọng số, nhưng không thể suy thành bộ nhớ GPU đỉnh hoặc thời gian chạy thực tế nếu chưa đo.

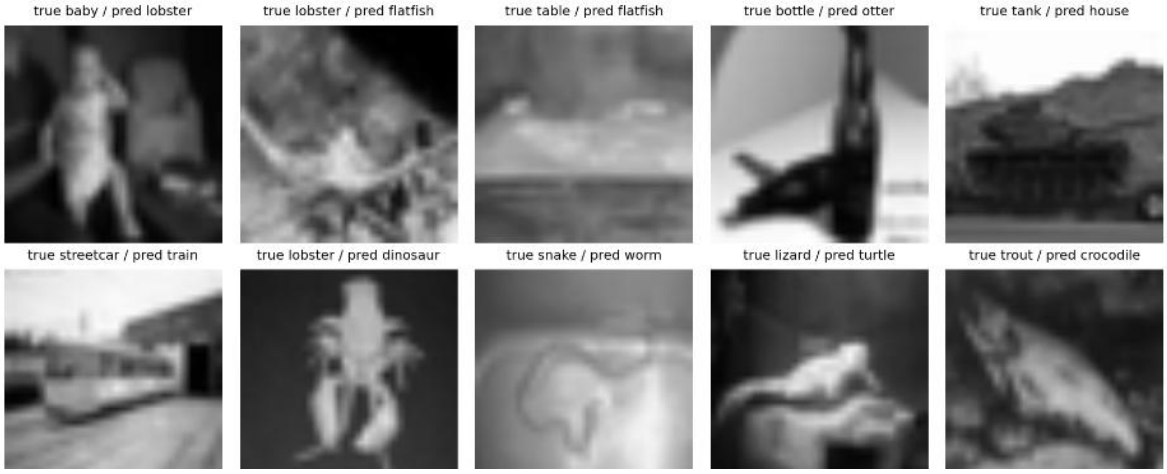
Thời gian ghi nhận thấp nhất thuộc ResNet chỉ đầu (1 giờ 24 phút 4 giây), còn ViT tinh chỉnh toàn bộ là 40 giờ 44 phút 46 giây. Tuy nhiên, các lượt được báo cáo chạy song song trong môi trường chưa kiểm soát và chưa biết cách chia tài nguyên. ViT chỉ đầu vẫn có thời lượng ghi nhận trên 26 giờ, điều này minh họa vì sao ít tham số được học không đồng nghĩa toàn bộ phép tính forward/backward hoặc thời gian quan sát sẽ nhỏ hơn theo cùng tỷ lệ. Không tính toán "nhanh hơn bao nhiêu lần" từ các mốc thời gian này.

5.9. Quan sát định tính qua các mẫu dự đoán sai

Các ảnh sai được lưu cùng nhãn thật (true) và nhãn mô hình dự đoán (pred) ở dạng tên lớp gốc của CIFAR-100. Hình 5.7 và 5.8 chỉ trích phần đầu của bảng mẫu sai đã cung cấp để nhãn đủ lớn khi in. Vì chương trình collect_predictions giữ tối đa 25 dự đoán sai đầu tiên khi duyệt tập test, các ảnh minh họa là ví dụ có thật chứ không phải lựa chọn ngẫu nhiên hoặc danh sách những lỗi thường gặp nhất.



Hình 5.7. Một số mẫu dự đoán sai của ResNet18 tinh chỉnh toàn bộ, giữ tên lớp tiếng Anh của nguồn (true: nhãn thật; pred: nhãn dự đoán). Nguồn: hình 15, cắt để dễ đọc.



Hình 5.8. Một số mẫu dự đoán sai của ViT-B/16 tinh chỉnh một phần; nguồn: hình 16, cắt để giữ khả năng đọc nhãn.

Ở ảnh ResNet18 toàn bộ, có những cặp được thấy trong bảng ảnh như "table" (bàn) thành "sea" (biển), "crab" (cua) thành "dinosaur" (khủng long), hoặc "rabbit" (thỏ) thành "forest" (rừng). Trong ví dụ ViT một phần, ảnh "lobster" (tôm hùm) có thể bị gán nhãn "flatfish" (cá bẹt), và "tank" (xe tăng) bị gán nhãn "house" (nhà). Các ví dụ này cho thấy thông tin kích thước nhỏ, bối cảnh lẫn vật thể có thể dẫn tới dự đoán không phù hợp, nhưng chưa đủ để phân định nguyên nhân của từng lỗi.

Các ma trận nhầm lẫn 100 × 100 cũng đã được lưu dưới dạng hình PNG ghép. Do mật độ nhãn và số trong mỗi ô rất cao, báo cáo chỉ có thể dùng chúng để nhận xét trực quan về sự hiện diện của đường chéo chính. Bộ tài liệu không kèm toàn bộ ma trận số hay nhãn dự đoán dạng mảng để xác định chắc chắn các cặp nhầm thường xuyên nhất. Vì vậy, không phát biểu tỷ lệ hay số lượng nhầm lớp suy ngược từ ô ảnh khó đọc.

Phần minh họa bổ sung trong phụ lục nhằm lưu dấu nguồn ảnh, không thay thế bảng định lượng per-class.

CHƯƠNG 6. THẢO LUẬN, GIỚI HẠN VÀ KẾT LUẬN

6.1. Những kết luận được hỗ trợ bởi thực nghiệm

Trên dữ liệu CIFAR-100 và các cấu hình đã ghi nhận, tiền huấn luyện đi cùng chiến lược mở tham số phù hợp có liên hệ với mức tăng độ chính xác đáng kể. ResNet18 tốt nhất khi tinh chỉnh toàn bộ, đạt 76,84%; ViT-B/16 tốt nhất khi tinh chỉnh một phần, đạt 83,25% và F1 trung bình theo lớp 0,8324. ViT chỉ học đầu vẫn đạt 81,32%, cho thấy biểu diễn pretrained có thể cho kết quả cao ngay cả khi chỉ cập nhật đầu phân loại. Tuy nhiên, hiệu quả thay đổi theo kiến trúc và chế độ: ResNet chỉ học đầu không vượt ResNet từ đầu, và ViT tinh chỉnh toàn bộ thấp hơn ViT tinh chỉnh một phần.

Điểm quan trọng không nằm ở lựa chọn một "kiến trúc thắng cuộc" bất biến, mà ở bằng chứng cho thấy khởi tạo trọng số, mức độ cho phép thích nghi và ổn định số học cùng quyết định kết quả. ViT từ đầu đạt thấp và mất ổn định, vì vậy không thể dùng riêng kết quả đó để khẳng định mô hình Transformer về bản chất không thể học từ đầu trên dữ liệu vừa. Tương tự, số tham số được học nhỏ hơn không bảo đảm thời gian ngắn hơn nếu thiết bị và chế độ phân bổ tài nguyên thay đổi.

6.2. Giới hạn kiểm chứng và khả năng tái lập

Hồ sơ đủ số liệu chất lượng và lịch sử cho tám cấu hình, nhưng có sự khác biệt về nguồn: ResNet18 partial và ViT scratch giữ JSON/CSV gốc, trong khi sáu cấu hình còn lại có test metrics và thời gian khôi phục từ console log. Các log này không xác nhận độc lập toàn bộ lệnh chạy, seed/split, batch size, learning rate, weight decay, phiên bản mô hình và checkpoint thực tế. Số tham số của sáu lượt được suy từ mã hiện tại nên cần so với phiên bản mã đã dùng nếu muốn công bố như thông số chính thức của từng lượt.

Không có các lần lặp nhiều seed, khoảng tin cậy hay kiểm định thống kê để lượng hóa độ biến động ngẫu nhiên. Chưa có đo bộ nhớ đỉnh, FLOPs thực tế, thời gian suy luận, năng lượng tiêu thụ và phép đo tốc độ được chuẩn hóa theo phần cứng. Bộ ảnh gốc không hiện diện trong tập hồ sơ đánh giá, và license chi tiết của CIFAR-100 chưa

được chốt qua nguồn đã kiểm tra. Hai lượt NaN cũng chưa được truy nguyên căn nguyên kỹ thuật. Những giới hạn này không phủ nhận chỉ số đã lưu, nhưng thu hẹp mức độ khái quát có thể rút ra từ chúng.

6.3. Hướng hoàn thiện trước khi công bố báo cáo cuối

Để củng cố phép so sánh, ưu tiên đầu tiên là xác nhận nguyên dòng lệnh, phiên bản torchvision/PyTorch, cờ nạp trọng số, loại GPU và điều kiện phân bổ tài nguyên cho cả tám lượt. Sau đó có thể chạy các đối chứng trong môi trường tài nguyên thống nhất với nhiều seed và lưu mean ± standard deviation. Đối với hai lượt ViT có NaN, cần ghi lại gradient và giá trị hữu hạn, thử learning rate khác nhau và các biện pháp ổn định trong một ma trận thí nghiệm riêng. Các bước này là kế hoạch gợi ý, không được nhập nhằng với kết quả đã báo cáo.

Bước hoàn thiện nội dung gồm kiểm tra điều khoản sử dụng dữ liệu, tái xuất confusion matrix hoặc y_true/y_pred dạng số để tính thống kê nhầm lớp đáng tin cậy, kiểm tra việc BatchNorm cập nhật thống kê khi đóng băng backbone, và đo bộ nhớ/tốc độ suy luận theo giao thức cố định. Cuối cùng, người học cần rà soát tài liệu Word, cập nhật mục lục, xuất PDF và liên kết trên GitHub Pages đúng yêu cầu của đề A1 [1].

6.4. Kết luận

Báo cáo đã hệ thống hóa quy trình xử lý dữ liệu, cấu hình mô hình, lựa chọn checkpoint và kết quả thực nghiệm của hai họ ResNet18 và ViT-B/16 theo bốn chế độ huấn luyện. Trên tập kiểm tra CIFAR-100 theo dữ liệu ghi nhận, ViT-B/16 tinh chỉnh một phần đạt 83,25%, là kết quả cao nhất trong tám cấu hình; ResNet18 tinh chỉnh toàn bộ đạt 76,84%, là kết quả cao nhất của họ CNN. Phân tích đường cong cũng cho thấy huấn luyện dài hơn có thể làm nới rộng khoảng cách train–validation, và hai lượt ViT phải được gắn cảnh báo NaN. Những kết quả này tạo cơ sở để tiếp tục kiểm chứng và tối ưu, thay vì thay thế các thí nghiệm tái lập có kiểm soát.

TÀI LIỆU THAM KHẢO

[1] Trường Đại học Bách khoa – ĐHQG TP.HCM. Bài tập lớn A1: CNN vs Transformer trên tập ảnh lớn, học phần CO5085, học kỳ 261 (2026–2027), tài liệu đề bài cung cấp.

[2] A. Krizhevsky, V. Nair và G. Hinton. CIFAR-10 and CIFAR-100 datasets. https://cave.cs.toronto.edu/kriz/cifar.html. Tài liệu nguồn dẫn đến A. Krizhevsky, Learning Multiple Layers of Features from Tiny Images, 2009.

[3] K. He, X. Zhang, S. Ren và J. Sun. Deep Residual Learning for Image Recognition. arXiv:1512.03385, 2015; xuất bản tại CVPR 2016. https://arxiv.org/abs/1512.03385.

[4] A. Dosovitskiy và cộng sự. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale. arXiv:2010.11929, 2020/2021. https://arxiv.org/abs/2010.11929.

[5] PyTorch. BatchNorm2d API documentation. https://docs.pytorch.org/docs/2.14/generated/torch.nn.BatchNorm2d.html (nguồn API được ghi nhận trong hồ sơ lý thuyết).

[6] Lê Thành Sách. Bài giảng nội bộ học phần CO5085: Loss Functions; Metrics; CNN Architectures; CNN Data Pipeline; Transformers: Model Families; Practical Finetuning and Efficiency. Không ghi năm công bố trên bộ slide đã cung cấp.

[7] Ngô Duy Bảo. Mã nguồn Assignment 1: A1/data.py, A1/models.py, A1/train.py, common/engine.py, common/plots.py. Kho mã: https://github.com/baond12/Deep_Learning_Course_HK261 (nguồn hiện thực của các thực nghiệm trong báo cáo).

PHỤ LỤC A. HỒ SƠ THỰC NGHIỆM VÀ KHẢ NĂNG KIỂM CHỨNG

A.1. Cách đọc nguồn chỉ số

Các tệp 06_METRICS_VA_NGUON.json và 07_KET_QUA_8_THUC_NGHIEM.csv chứa tám bộ kết quả cuối. Tệp 08_LICH_SU_400_EPOCH.csv gồm 400 hàng train/validation; tệp 17_DANH_MUC_KIEM_CHUNG.csv cho biết xuất xứ, độ chính xác và tình trạng xác nhận metadata. Việc lựa chọn best epoch đã đối chiếu với lịch sử. Test loss, test accuracy và macro F1 không suy ra từ history, vì history chỉ chứa metric trên tập học và xác thực.

resnet18_scratch: Log khôi phục; best epoch 19; val 61,64%; test 60,97%; NaN từ epoch không phát hiện trong lịch sử.

resnet18_pretrained_head: Log khôi phục; best epoch 40; val 61,08%; test 60,47%; NaN từ epoch không phát hiện trong lịch sử.

resnet18_pretrained_partial: JSON gốc; best epoch 7; val 72,83%; test 72,27%; NaN từ epoch không phát hiện trong lịch sử.

resnet18_pretrained_full: Log khôi phục; best epoch 11; val 77,29%; test 76,84%; NaN từ epoch không phát hiện trong lịch sử.

vit_b16_scratch: JSON gốc; best epoch 10; val 35,37%; test 35,30%; NaN từ epoch 11.

vit_b16_pretrained_head: Log khôi phục; best epoch 19; val 82,18%; test 81,32%; NaN từ epoch không phát hiện trong lịch sử.

vit_b16_pretrained_partial: Log khôi phục; best epoch 27; val 83,66%; test 83,25%; NaN từ epoch không phát hiện trong lịch sử.

vit_b16_pretrained_full: Log khôi phục; best epoch 3; val 78,73%; test 78,64%; NaN từ epoch 37.

A.2. Lệnh tái lập theo thiết kế mã nguồn

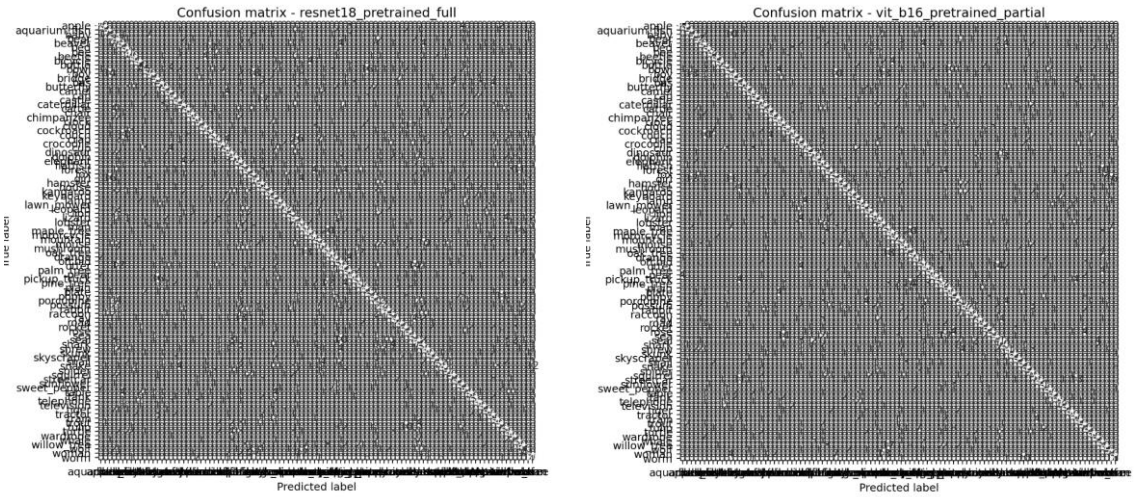
Đoạn sau minh họa giao diện chạy của repository; không được hiểu là nguyên dòng lệnh đã xác nhận cho sáu kết quả bổ sung. Trước khi tái chạy cần chuẩn bị CIFAR-100 ở cùng thư mục dữ liệu và chọn chính xác tham số phù hợp với giao thức cần kiểm chứng.

```
python A1/prepare_data.py --data-dir data
python A1/train.py --data-dir data --experiments all --epochs 50 --batch-size 16 --learning-rate 0.0001 --weight-decay 0.0001 --seed 42 --device cuda
python A1/analyze_results.py --results-dir A1/results
```

Chú ý: tên mode “pretrained” trong lệnh chưa đủ chứng minh checkpoint được nạp; cần kiểm tra cờ --no-download-weights, metadata và phiên bản gói.

PHỤ LỤC B. HÌNH MA TRẬN NHẦM LẪN (MINH HỌA TỔNG QUAN)

Hai hình dưới là phần cắt từ ma trận nhầm lẫn gốc dạng PNG của ResNet18 tinh chỉnh toàn bộ và ViT-B/16 tinh chỉnh một phần. Do có 100 lớp và nguồn ảnh chưa có bảng số dạng máy đọc được, ma trận chỉ hỗ trợ quan sát tổng quan, không dùng để đọc số đếm từng ô hoặc xác định các cặp nhầm phổ biến nhất. Khi cần phân tích định lượng theo lớp phải xuất ma trận hoặc các mảng nhãn y_true, y_pred từ chương trình.



ResNet18 toàn bộ ViT-B/16 một phần

Hình B.1. Ma trận nhầm lẫn 100 lớp của hai cấu hình được chọn (trích hình 13–14); chỉ minh họa cấu trúc tổng quát đường chéo, không đọc số lượng từng ô.

PHỤ LỤC C. TUYÊN BỐ HỖ TRỢ CỦA TRÍ TUỆ NHÂN TẠO

Công cụ trí tuệ nhân tạo được sử dụng để hỗ trợ đọc, đối chiếu các tài liệu và chỉ số đã cung cấp; hệ thống hóa cấu trúc báo cáo, diễn đạt học thuật bằng tiếng Việt, hỗ trợ tạo biểu đồ từ dữ liệu lịch sử và soạn bản nháp Word. Nội dung do công cụ hỗ trợ không thay thế việc người học kiểm chứng mã nguồn, kết quả, trích dẫn và các kết luận nghiên cứu. Người học có trách nhiệm đọc lại, chỉnh lý, xác nhận những thông tin còn thiếu và chịu trách nhiệm về bản báo cáo cuối cùng.